



Trabajo Práctico 4

Ciencia de Datos

Alumnas

Juana Cisneros, Francesca Lo Tartaro , Lucía Martín

Profesores

María Noelia Romero, Ignacio Anchorena

Asignatura

Ciencia de Datos

Teórica 1 - Tutorial 2.


Semestre y año de presentación

2do Semestre 2025

Link al repositorio: <https://github.com/lucia1martin/Trabajo-Practico-4>

A. Modelo de Regresión Logística con Regularización: Ridge y LASSO

1. Gráfico 1: Coeficientes del modelo logístico con penalización L1 (LASSO) & penalización L2 (Ridge)




En el gráfico del *modelo logístico con penalización L1 (LASSO)* se observa que, para valores bajos de λ , los coeficientes son similares a los del modelo logístico sin regularización, mientras que a medida que aumenta λ (hacia la derecha en el eje de $\log_{10}(\lambda)$) varios coeficientes se reducen rápidamente hasta volverse exactamente cero. Esto indica que la penalización L1 actúa como un mecanismo selector de variables: a niveles altos de regularización, el modelo mantiene sólo un subconjunto reducido de predictores y descarta el resto, simplificando la especificación, quitando el ruido y disminuyendo el riesgo de sobreajuste. También, se puede observar trayectorias de predictores que se mueven de forma casi paralela formando “triángulos” que sugieren la presencia de variables altamente correlacionadas entre sí. LASSO interviene frente a esta multicolinealidad seleccionando solo alguna de ellas y lleva al resto a coeficientes próximos a cero.

En cambio, en el gráfico con penalización L2 (Ridge) los coeficientes también se acercan a cero cuando crece λ , pero lo hacen de manera suave y continua, sin anularse por completo. Todas las variables permanecen en el modelo, aunque con valores de coeficientes más pequeños. Esta regularización no quita variables, sino que achica los coeficientes y los vuelve más estables, especialmente en presencia de predictores correlacionados y en presencia de multicolinealidad.

Para resumir, ambos gráficos muestran cómo LASSO controla la complejidad principalmente eliminando coeficientes que no aportan de manera significativa al modelo, mientras que Ridge lo hace reduciendo su tamaño de forma global.

2. Gráfico 2: Penalidad óptima por Cross-validation y visualización



En los boxplot de *Penalidad óptima por Cross-validation y visualización* se observa cómo varía el error de clasificación para distintos niveles de penalización λ . En el caso de LASSO, se observa que, para valores bajos y moderados de λ , el error de validación se mantiene prácticamente constante y en torno a 0,313. En cambio, cuando la penalización es alta, ($\log_{10}(\lambda) \geq 2$), el error aumenta levemente lo que indica que un exceso de regularización podría llevar a un modelo demasiado simple (subajustado), empeorando su capacidad predictiva. Por otro lado, en el caso de RIDGE, el error de validación es casi idéntico para todos los valores de λ , lo que sugiere que, la regularización en esta aplicación apenas modifica la tasa de error. Es decir, el desempeño del modelo es estable en toda la grilla de penalización.

3. **Tabla 1:** Estimación con λ y comparación de coeficientes

Variable	Logit sin penalización	Logit L2 RIDGE	Logit L1 LASSO
Intercepto	-0.2266	-0.2267	-0.0268
Edad	-0.0024	-0.0024	-0.0024
Horas trabajadas en la semana	0.0015	0.0015	0.0015
Sexo	0.0199	0.0199	0.0196
obra social en el trabajo	-0.5508	-0.5510	-0.5506
Estado civil: Unido	-0.2502	-0.2502	-0.5545
Estado civil: Casado	-0.0761	-0.0761	-0.3813
Estado civil: Divorciado	0.0829	0.0829	-0.2216
Estado civil: Viudo/a	-0.0166	-0.0166	-0.3211
Estado civil: Soltero/a	0.0334	0.0334	-0.2706
N. E. : Primario incompleto	0.0440	0.0441	-0.1516
N. E. : Primario completo	0.0493	0.0494	-0.1469
N. E. : Secundario incompleto	-0.0589	-0.0589	-0.2533
N. E. : Secundario completo	-0.0665	-0.0665	-0.2620
N. E. : Universitario incompleto	-0.0971	-0.0972	-0.2916


N. E. : Universitario completo	-0.0974	-0.0974	-0.2926
N. E. : Sin instrucción	-0.0001	-0.0001	-0.2134

Aclaración: N.E. = Nivel educativo.

En comparación con el logit sin penalidad, tanto L1 como L2 reducen la magnitud de los coeficientes, pero lo hacen de manera diferente. Por un lado, Ridge (L2) apenas achica los betas para bajar la varianza y estabilizar el modelo. Por otro lado LASSO (L1) los reduce mucho más y modifica sus valores de manera visible. Al observar la tabla, vemos que en LASSO varios coeficientes se acercan fuertemente a cero, lo que indica tendencia a la selección de variables respecto a los betas originales del entrenamiento. Sin embargo, en esta estimación particular ningún coeficiente llega exactamente a cero, por lo que LASSO no elimina completamente ninguna de las variables que incluimos en X_{train} , aunque sí las debilita. En cambio, Ridge no elimina variables, sino que suaviza sus efectos manteniendo la misma estructura del modelo sin penalizar. En conjunto, la regularización reduce la influencia de predictores débiles, y LASSO lo hace de manera más marcada que Ridge.

B. Árboles


4. Gráfico 3: CART podado - Año 2025



El gráfico muestra que el error de clasificación disminuye de manera pronunciada a medida que aumentamos el α desde valores muy pequeños, lo que indica que el árbol inicial estaba sobreajustado y se beneficiaba de una poda más fuerte. A partir de aproximadamente $\alpha \approx 0.006$ (alfa óptimo), el error se estabiliza y alcanza su mínimo (0.31), lo que justifica la elección de ese valor como hiperparámetro óptimo según la validación cruzada. Valores mayores de α no mejoran el desempeño y podrían generar subajuste, ya que simplifican demasiado el árbol sin reducir el error. Finalmente, la accuracy CV media del 10-fold (≈ 0.686) confirma que el árbol podado generaliza

mejor que el árbol sin regularización, manteniendo un equilibrio adecuado entre complejidad y desempeño.

5. Gráfico 5: Visualización del árbol podado por cross-validation



En este caso, la poda seleccionada por cross-validation elige un valor de alfa lo suficientemente grande como para eliminar todos los splits del árbol. Por este motivo, el árbol podado se reduce a un único nodo raíz, sin ramas ni decisiones intermedias; en consecuencia, el Panel A no muestra divisiones porque el modelo no utiliza ninguna variable para clasificar. Esta misma razón explica por qué el Panel B aparece vacío, dado que al no existir splits, ningún predictor participa en el árbol y la importancia de todas las variables es exactamente cero, porque no hay variables que clasificar. Además, este comportamiento es coherente con el desempeño del modelo, cuyo $AUC \approx 0.50$ (punto 6) indica que el árbol podado se comporta prácticamente como un clasificador aleatorio, sin capacidad discriminativa.

Dado que el árbol podado no utiliza ningún predictor, no puede establecerse una correspondencia entre estas importancias nulas y las variables que LASSO reduce a cero, porque ambos métodos aplican criterios distintos de selección. El árbol aparece “vacío” por efecto de la poda óptima, no porque las variables carezcan de relevancia, sino porque el modelo final no realiza ninguna partición basada en ellas.

C. Comparación entre métodos

6. Tabla 2: Comparación con Trabajo Práctico 3

Modelo	Exactitud	AUC ROC	1 - accuracy
Logit sin penalidad	0.686714	0.587848	0.313286
KNN (K=19)	0.672255	0.557337	0.327745
Logit LASSO (L1)	0.686714	0.587830	0.313286
Logit RIDGE (L2)	0.686714	0.587848	0.313286
Árbol podado (CART)	0.686295	0.500000	0.313705

Gráfico 6: Matrices de confusión por modelo ($p > 0,5$) — 2025





Gráfico 7: Curvas ROC comparadas por modelo — 2025



En la comparación entre métodos (La matriz de confusión ($p > 0,5$), la curva ROC y las dos métricas que utilizó en el TP3 (Tabla 2 y Gráficos 6 y 7)) se observa que las tres regresiones logísticas (sin penalidad, con LASSO (L1) y con Ridge (L2)) alcanzan una **exactitud** similar, en torno a 0,68, con un **error de clasificación** (1-accuracy) cercano al 31,3% y un área bajo la **curva ROC** (AUC ROC) de aproximadamente 0,588.

Por otro lado, el modelo KNN (K=19), presenta un desempeño minamente peor (exactitud 0,672 y AUC 0,557), mientras que el el árbol podado (CART), tiene una exactitud parecida a las regresiones logísticas pero con una AUC ROC de 0,5, lo que significa que discrimina entre pobres y no pobres de forma prácticamente aleatoria. En conjunto, las diferencias en 1-accuracy entre métodos

son muy pequeñas y no aparece una ganancia clara por utilizar modelos no lineales como KNN o CART

Las matrices de confusión (Gráfico 6) muestran que, tanto las regresiones logísticas como el árbol no asignan ningún falso positivo, logrando una alta accuracy pero con un umbral alto de falso negativo, prediciendo que *no es pobre cuando en realidad sí lo es*. Este error es el más relevante ya que pensar que casi $\frac{1}{3}$ de la muestra no es pobre cuando sí lo es implica que muchos individuos que realmente necesitan ayuda no la reciban, lo que puede traer consecuencias significativas. Por otro lado, KNN recupera algo más de casos pobres a costa de un mayor error total. (Trade-off: Tiene una mayor tasa de verdaderos positivos pero también aumenta el número de falsos positivos.)

Para concluir, el análisis muestra que, aunque los modelos no lineales como KNN o CART pueden tener ciertas ventajas en otros contextos, en este conjunto de datos particular no se destaca una mejora significativa en el rendimiento comparado con la regresión logística. Aunque no aparece un modelo claramente superior en términos de exactitud, AUC ROC y error, la regresión logística tiene la ventaja de ser la más interpretable, especialmente cuando se usa penalización LASSO, que ayuda a simplificar el modelo y a destacar las variables más relevantes, haciendo más transparente las relación entre las variables y la probabilidad de ser pobre.

7. Programa de alimentos: Grupos vulnerables

En el caso de que el Ministerio de Capital Humano está interesado en identificar a grupos vulnerables para dirigir los recursos de un programa de alimentos utilizaremos un modelo que priorice minimizar los falsos negativos, es decir, no dejar afuera del programa a personas que son pobres por predecir que no lo son, incluso a costa de permitir un mayor número de falsos positivos. En ese sentido, el modelo **KNN** puede ser el más ventajoso, porque al ser un modelo más flexible clasifica como “pobre” a más hogares, priorizando una mayor sensibilidad a costa de una menor especificidad.

Para un programa de alimentos orientado a no excluir hogares vulnerables, el criterio de decisión debería centrarse en minimizar los falsos negativos, aun a costa de incrementar el número de falsos positivos, ya que el costo social de dejar fuera a un pobre es mayor que el de incluir a un no pobre.